Aprendizado por Reforço

Trading de ativos com `gym-trading-env`

Tiago Macedo Viktor Mayer Enzo Guedes

IBMEC

30 de outubro de 2026

1. Definição do Estado e das Ações

O agente observa o regime de tendência do ativo e a sua posição corrente em carteira:

$$\mathbf{s_t} = (\mathbf{x_t}, \mathbf{x_{t-1}}, \mathbf{h_{t-1}})$$

onde $h_{t-1} \in \{-1, 0, +1\}$ é a **posição mantida (holding)** anterior, atualizada por $h_t = a_t$.

Sinal de Tendência (x_t)

Desvio em relação à média móvel de 50 períodos:

$$x_t = \ln\left(\frac{c_t}{\mathrm{MA}_{50}(c_t)}\right)$$

- c_t: preço de fechamento no instante t.
- MA_{50}: média aritmética móvel de 50 dias.
- $x_t > 0$: regime altista; $x_t < 0$: baixista.

Espaço de Ações ($\mathcal{A}$)

Postura operacional selecionada ($a_t \in \mathcal{A}$):

$$\mathcal{A} = \{-1,\ 0,\ +1\}$$

- -1: vendido (*short*).
- 0: neutro (fora de posição).
- $+1$: comprado (*long*).

2. Discretização do Estado

Indicador de Tendência (x_t)

Preço relativo à média móvel de 50 períodos:

$$x_t = \ln\left(\frac{c_t}{\mathrm{MA}_{50}(c_t)}\right)$$

Discretização em 3 faixas via tercis do treino:

$$\phi(x) = \begin{cases} 0, & x \le \tau_1 \quad \text{(tendência de baixa)}, \\ 1, & \tau_1 < x \le \tau_2 \quad \text{(regime neutro)}, \\ 2, & x > \tau_2 \quad \text{(tendência de alta)}. \end{cases}$$

Espaço Discreto ($\mathcal{S}$)

Vetor discretizado:

$$\tilde{s}_t = \big(\phi(x_t),\, \phi(x_{t-1}),\, h_{t-1}\big)$$

Produto cartesiano:

$$\mathcal{S} = \{0,1,2\}^2 \times \{-1,0,+1\}$$

Cardinalidade finita:
$|\mathcal{S}| = 3^2 \times 3 = \mathbf{27}$ estados

A feature x_t captura ciclos de médio prazo em vez de ruído diário puro,
reduzindo rotações excessivas da carteira e preservando o capital frente aos custos de transação.

3. Recompensa e Modelo de Transição

Função de Recompensa (Log-Retorno do Patrimônio)

Sendo W_t o patrimônio no instante t, a recompensa imediata é o retorno logarítmico:

$$R_{t+1} = \ln\left(\frac{W_{t+1}}{W_t}\right) = \ln(g_{t+1})$$

onde g_{t+1} é o **fator de crescimento líquido da carteira** ($W_{t+1} = W_t \cdot g_{t+1}$):

$$g_{t+1} = \underbrace{1}_{\text{capital base}} + \underbrace{a_t\, r_{t+1}}_{\text{retorno do ativo}} - \underbrace{\kappa|a_t - h_{t-1}|}_{\text{taxa de corretagem}} \qquad (g_{t+1} > 0)$$

- $r_{t+1} = \frac{c_{t+1}}{c_t} - 1$: retorno linear do ativo no período.
- $\kappa|a_t - h_{t-1}|$: custo operacional debitado a cada mudança de posição ($\kappa = 0{,}1\%$).
- Transição pretendida: $\tilde{s}_{t+1} = \big(\phi(x_{t+1}),\, \phi(x_t),\, a_t\big)$. A dinâmica de mercado é estimada a partir dos dados históricos.
- No simulador, a exposição vendida mantida pode não ser rebalanceada diariamente para -100%; por isso, a recompensa do ambiente pode diferir da fórmula simplificada nos períodos de *short* mantido.

4. Funções de Valor e Transição para *Model-Based*

Equações de Bellman para uma Política π

A função estado-valor $V^{\pi}(s)$ pondera as ações sob a política:

$$V^{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) Q^{\pi}(s, a)$$

A função ação-valor $Q^{\pi}(s, a)$ projeta o retorno futuro acumulado:

$$Q^{\pi}(s, a) = \sum_{s' \in \mathcal{S}} \widehat{P}(s' \mid s, a) \left[\widehat{R}(s, a, s') + \gamma V^{\pi}(s') \right]$$

Inferência da Dinâmica: de *Model-Free* a *Model-Based*

O simulador de mercado não fornece a matriz analítica de transições. Estimamos $\widehat{P}$ e $\widehat{R}$ diretamente da base de treino, viabilizando o cálculo exato do **Value Iteration**.

5. Inferência Empírica

Matriz de Transição Empírica ($\widehat{P}$)

$$\widehat{P}(s' \mid s, a) = \frac{N(s, a, s')}{N(s, a)}$$

Recompensa Esperada ($\widehat{R}$)

$$\widehat{R}(s, a, s') = \frac{1}{N(s, a, s')} \sum_{k=1}^{N(s,a,s')} \ln\left(1 + a \cdot r_{t+1}^{(k)} - \kappa|a - h_{t-1}|\right)$$

A recompensa usa o retorno bruto linear r_{t+1}; x_t apenas indexa o estado.

Matriz de Transição $\widehat{P}$ estimada no treino

$(\phi(x_t), \phi(x_{t-1}))$	(0,0)	(0,1)	(0,2)	(1,0)	(1,1)	(1,2)	(2,0)	(2,1)	(2,2)
$\phi(x_{t+1}) = 0$	0,933	0,900	0,333	0,322	0,053	0,016	0,000	0,000	0,000
$\phi(x_{t+1}) = 1$	0,066	0,100	0,333	0,678	0,889	0,672	1,000	0,333	0,052
$\phi(x_{t+1}) = 2$	0,001	0,000	0,333	0,000	0,057	0,312	0,000	0,667	0,948

6. *Value Iteration* e Política Ótima

Equação de Otimalidade de Bellman (Value Iteration)

$$V_{k+1}(s) = \max_{a \in \mathcal{A}} \left[\sum_{s' \in \mathcal{S}} \widehat{P}(s' \mid s, a) \Big(\widehat{R}(s, a, s') + \gamma V_k(s') \Big) \right]$$

O algoritmo avalia exaustivamente todas as ações $a \in \{-1, 0, +1\}$ para todos os 27 estados até a convergência com tolerância tol $< 10^{-12}$ (**419 iterações**).

Política ótima: $\pi^*(s) = \arg\max_a Q^*(s, a)$

$(\phi(x_t), \phi(x_{t-1}))$	**Regime**	$h_{t-1} = -1$	$h_{t-1} = 0$	$h_{t-1} = +1$
(0,0)	Baixa estável	0	0	0
(0,1)	Neutro → Baixa	−1	−1	−1
(0,2)	Alta → Baixa	−1	0	+1
(1,0)	Baixa → Neutro	−1	0	0
(1,1)	Neutro estável	+1	+1	+1
(1,2)	Alta → Neutro	+1	+1	+1
(2,0)	Baixa → Alta	−1	−1	−1
(2,1)	Neutro → Alta	+1	+1	+1
(2,2)	Alta estável	+1	+1	+1

Leitura da política

- **Baixa estável:** sai do mercado.
- **Entrando na baixa:** vende (*short*).
- **Neutro ou alta:** fica comprado.
- **Saindo da baixa para neutro:** espera, sem comprar.

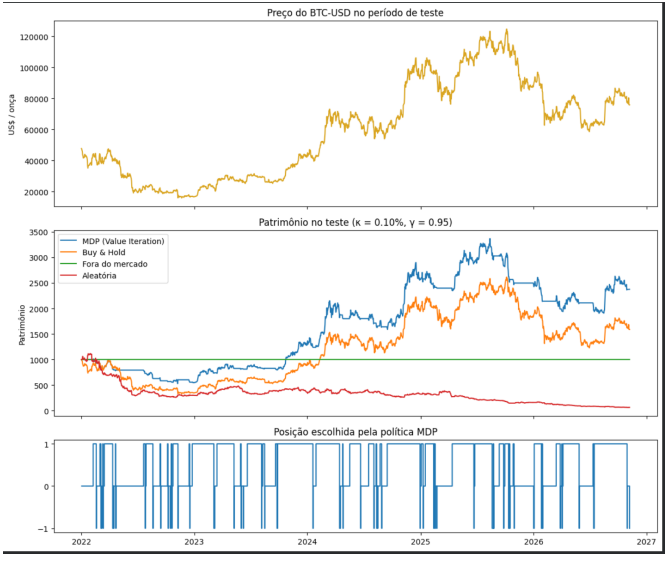
7. Resultados Empíricos no gym-trading-env

Avaliação no gym-trading-env ($\kappa = 0{,}1\%$, $\gamma = 0{,}8$)

Estratégia	Retorno Total	Retorno Anual	Índice de Sharpe	Max Drawdown	Nº de Trocas
Teste (a partir de 01/01/2022; 1.770 passos na execução reportada)					
MDP (Value Iteration)	**137,44%**	**19,52%**	**0,51**	**-47,93%**	**135**
MDP ϵ-greedy ($\epsilon = 0{,}1$)	110,28%	16,56%	0,43	-49,48%	327
Buy & Hold	58,81%	10,01%	0,19	-66,93%	1
Fora do Mercado	0,00%	0,00%	0,00	0,00%	0
Aleatória ($\epsilon = 1$)	-93,70%	-43,46%	-1,35	-94,54%	1.155
Treino (antes de 01/01/2022; 2.612 passos na execução reportada)					
MDP (Value Iteration)	**20.389,96%**	**110,38%**	**1,31**	**-56,26%**	**155**
MDP ϵ-greedy ($\epsilon = 0{,}1$)	3.636,41%	65,86%	0,89	-54,75%	442
Buy & Hold	13.144,05%	97,94%	0,91	-83,40%	1
Fora do Mercado	0,00%	0,00%	0,00	0,00%	0
Aleatória ($\epsilon = 1$)	-88,73%	-26,29%	-0,51	-95,74%	1.721

ϵ-greedy: com probabilidade ϵ o agente escolhe uma ação aleatória, ou seja, $\pi(a^* \mid s) = 1 - \epsilon + \epsilon/3$.

8. Desempenho no Período de Teste



Benchmark Completo Fora da Amostra (Teste)

Tabela Comparativa de Estratégias (Ordenada por Índice Sharpe)

Estratégia / Modelo	Retorno Total	Retorno Anual	Índice Sharpe	Max Drawdown	Trocas
MDP (Value Iteration)	**+136,28%**	**+19,64%**	**0,51**	**-70,22%**	**135**
Support Vector Machine (SVM)	+209,50%	+26,57%	0,42	-76,76%	93
Classificador Ridge (L2)	+198,89%	+25,65%	0,41	-75,83%	69
Buy & Hold (Referência)	+108,30%	+16,54%	0,26	-67,35%	1
Regressão Lasso (L1)	+108,30%	+16,54%	0,26	-67,35%	1
Regressão Linear (OLS) / MA50	+57,99%	+10,01%	0,23	-62,13%	105
Random Forest	+49,78%	+8,79%	0,14	-51,53%	600
Árvore de Decisão (CART)	-56,93%	-16,11%	-0,39	-70,34%	611
Gradient Boosting	-89,20%	-37,14%	-0,95	-92,38%	590
K-Nearest Neighbors (KNN)	-90,77%	-39,16%	-1,02	-93,43%	718

Eficiência Ajustada ao Risco

- O **MDP atingiu a melhor relação risco-retorno** (Sharpe $= 0{,}51$).
- SVM e Ridge obtiveram maior retorno nominal, porém com volatilidade e *drawdowns* excessivos (-76%).

O Impacto do Atrito Operacional

- Modelos não lineares complexos (KNN, Boosting) colapsaram devido ao *overtrading* (> 590 trocas).
- O MDP conteve o atrito integrando a posição anterior h_{t-1} na função de valor de Bellman.